Ouvidoria Inteligente

Relatório técnico — triagem semântica de manifestações cidadãs

1. Objetivo e corpus

A proposta implementa um protótipo de busca semântica para um corpus sintético de 40 manifestações, com cinco categorias oficiais: infraestrutura, saúde, segurança, educação e meio ambiente. Os textos permanecem na faixa de 50 a 800 caracteres e cinco registros foram construídos como manifestações longas. Três pares são considerados duplicatas semânticas, cobrindo seis dos quarenta registros.

2. Representações

A análise compara BoW, TF-IDF e embeddings densos. BoW depende de coincidência lexical; TF-IDF reduz o peso de termos muito frequentes; embeddings multilíngues procuram representar significado mesmo quando a redação muda. Dois modelos multilíngues ficam disponíveis para comparação.

3. Duplicatas

A função detectar_duplicatas calcula o cosseno entre embeddings normalizados e retorna pares acima de um limiar. O valor inicial de 0,85 segue o desafio. O notebook também percorre thresholds próximos para observar precisão, recall, falsos positivos e falsos negativos. O resultado deve ser tratado como candidato à revisão humana.

4. Chunking

As cinco manifestações mais longas são processadas com RecursiveCharacterTextSplitter. Duas configurações de chunk_size e chunk_overlap são comparadas. Overlap maior preserva mais contexto nas fronteiras, mas aumenta a repetição e o número de vetores. A análise inclui uma projeção 2D dos chunks.

5. Aplicação Streamlit

A aplicação possui quatro áreas: Busca Semântica, Base Completa, Espaço Vetorial e Chunking. A busca apresenta os cinco itens mais próximos e usa as faixas de cor do enunciado. A base gera uma matriz 40×40; o espaço vetorial oferece PCA e t-SNE; o chunking permite testar parâmetros e visualizar os vetores dos pedaços.

6. Decisões e limitações

O corpus é sintético e pequeno, portanto não permite concluir desempenho em uma ouvidoria real. PCA e t-SNE são projeções e podem distorcer relações. Embeddings podem aproximar problemas da mesma categoria sem indicar que se trata do mesmo evento. O limiar de duplicata precisa ser calibrado com dados rotulados maiores. A separação entre núcleo de NLP e interface facilita testes e manutenção.

7. Reprodutibilidade

Instale requirements.txt, execute streamlit run app_ouvidoria.py e abra os três notebooks em ordem. O projeto inclui o corpus, a referência dos pares duplicados e scripts reutilizáveis. Os modelos de sentence-transformers podem ser baixados na primeira execução.

Observação: integrantes e divisão de tarefas devem refletir a autoria real do trabalho.